

Métodos Matriciais Computacionais

Análise Matricial Decomposição em valores singulares

Prof.^a Cibele Aparecida Ladeia



Decomposição em valores singulares

- A **decomposição em valores singulares**, ou inglês, *singular value decomposition (SVD)* é uma forma muito importante de decomposição de matrizes.



Decomposição em valores singulares

- A **decomposição em valores singulares**, ou inglês, *singular value decomposition (SVD)* é uma forma muito importante de decomposição de matrizes.
- SVD é aplicável até mesmo para matrizes não quadradas com entradas complexas, mas para maior clareza, restringiremos nosso tratamento inicial a matrizes com entradas reais.



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais

$$U = [u_1 | \dots | u_m] \in \mathbb{R}^{m \times m}$$



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais

$$U = [u_1 | \dots | u_m] \in \mathbb{R}^{m \times m} \quad \text{e} \quad V = [v_1 | \dots | v_n] \in \mathbb{R}^{n \times n}$$



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais

$$U = [u_1 | \dots | u_m] \in \mathbb{R}^{m \times m} \quad \text{e} \quad V = [v_1 | \dots | v_n] \in \mathbb{R}^{n \times n}$$

tais que



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais

$$U = [u_1 | \dots | u_m] \in \mathbb{R}^{m \times m} \quad \text{e} \quad V = [v_1 | \dots | v_n] \in \mathbb{R}^{n \times n}$$

tais que

$$U^T A V = \Sigma = \text{diag}(\sigma_1, \dots, \sigma_p) \in \mathbb{R}^{m \times n},$$



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais

$$U = [u_1 | \dots | u_m] \in \mathbb{R}^{m \times m} \quad \text{e} \quad V = [v_1 | \dots | v_n] \in \mathbb{R}^{n \times n}$$

tais que

$$U^T A V = \Sigma = \text{diag}(\sigma_1, \dots, \sigma_p) \in \mathbb{R}^{m \times n}, \quad p = \min\{m, n\},$$



Decomposição em valores singulares

Teorema 1 (SVD): Se A é uma matriz real ($A \in \mathbb{R}^{m \times n}$) existem matrizes ortogonais

$$U = [u_1 | \dots | u_m] \in \mathbb{R}^{m \times m} \quad \text{e} \quad V = [v_1 | \dots | v_n] \in \mathbb{R}^{n \times n}$$

tais que

$$U^T A V = \Sigma = \text{diag}(\sigma_1, \dots, \sigma_p) \in \mathbb{R}^{m \times n}, \quad p = \min\{m, n\},$$

onde $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$.



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.
 - ▶ **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$),



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.
 - ▶ **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$), então existe $V_2 \in \mathbb{R}^{n \times (n-r)}$, de forma que $V = [V_1 | V_2]$ é ortogonal.



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.
 - ▶ **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$), então existe $V_2 \in \mathbb{R}^{n \times (n-r)}$, de forma que $V = [V_1 | V_2]$ é ortogonal.
 - ▶ Dem: Se $V \in \mathbb{R}^{n \times n}$ é uma matriz ortogonal, $V^T V = I$.



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.
- ▶ **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$), então existe $V_2 \in \mathbb{R}^{n \times (n-r)}$, de forma que $V = [V_1 | V_2]$ é ortogonal.
- ▶ Dem: Se $V \in \mathbb{R}^{n \times n}$ é uma matriz ortogonal, $V^T V = I$. Se dizemos que $V = [v_1 | \dots | v_n]$,



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.
 - ▶ **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$), então existe $V_2 \in \mathbb{R}^{n \times (n-r)}$, de forma que $V = [V_1 | V_2]$ é ortogonal.
 - ▶ Dem: Se $V \in \mathbb{R}^{n \times n}$ é uma matriz ortogonal, $V^T V = I$. Se dizemos que $V = [v_1 | \dots | v_n]$, então v_i forma uma base ortonormal em $\mathbb{R}^n$.



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.
- ▶ **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$), então existe $V_2 \in \mathbb{R}^{n \times (n-r)}$, de forma que $V = [V_1 | V_2]$ é ortogonal.
- ▶ Dem: Se $V \in \mathbb{R}^{n \times n}$ é uma matriz ortogonal, $V^T V = I$. Se dizemos que $V = [v_1 | \dots | v_n]$, então v_i forma uma base ortonormal em $\mathbb{R}^n$. Portanto, se $V_1 = [v_1 | \dots | v_r]$ e sabemos que $v_i, i = 1, 2, \dots, r$, são colunas ortonormais



Decomposição em valores singulares

- Antes de iniciarmos a demonstração do **Teorema SVD**, iremos apresentar um resultado importante da Álgebra Linear, que será utilizado na demonstração.

► **Teorema 2:** Se $V_1 \in \mathbb{R}^{n \times r}$ tem colunas ortonormais ($r < n$), então existe $V_2 \in \mathbb{R}^{n \times (n-r)}$, de forma que $V = [V_1 | V_2]$ é ortogonal.

► Dem: Se $V \in \mathbb{R}^{n \times n}$ é uma matriz ortogonal, $V^T V = I$. Se dizemos que $V = [v_1 | \dots | v_n]$, então v_i forma uma base ortonormal em $\mathbb{R}^n$. Portanto, se $V_1 = [v_1 | \dots | v_r]$ e sabemos que v_i , $i = 1, 2, \dots, r$, são colunas ortonormais podemos construir $V_2 = [v_{r+1} | \dots | v_n]$ de forma que

$$V = \left[\underbrace{v_1 | v_2 | \dots | v_r}_{V_1} \underbrace{v_{r+1} | \dots | v_n}_{V_2} \right]$$

seja ortogonal.



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$,



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$.



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$. Do teorema 2 sabemos que existe $V_2 \in \mathbb{R}^{n \times (n-1)}$ e $U_2 \in \mathbb{R}^{m \times (m-1)}$ de forma que $V = [x \mid V_2] \in \mathbb{R}^{n \times n}$ e $U = [y \mid U_2] \in \mathbb{R}^{m \times m}$ sejam ortogonais.



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$. Do teorema 2 sabemos que existe $V_2 \in \mathbb{R}^{n \times (n-1)}$ e $U_2 \in \mathbb{R}^{m \times (m-1)}$ de forma que $V = [x \mid V_2] \in \mathbb{R}^{n \times n}$ e $U = [y \mid U_2] \in \mathbb{R}^{m \times m}$ sejam ortogonais. Podemos, então escrever

$$U^T A V$$



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$. Do teorema 2 sabemos que existe $V_2 \in \mathbb{R}^{n \times (n-1)}$ e $U_2 \in \mathbb{R}^{m \times (m-1)}$ de forma que $V = [x \mid V_2] \in \mathbb{R}^{n \times n}$ e $U = [y \mid U_2] \in \mathbb{R}^{m \times m}$ sejam ortogonais. Podemos, então escrever

$$U^T A V = \begin{bmatrix} y^T \\ U_2^T \end{bmatrix} A \begin{bmatrix} x \mid V_2 \end{bmatrix}$$



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$. Do teorema 2 sabemos que existe $V_2 \in \mathbb{R}^{n \times (n-1)}$ e $U_2 \in \mathbb{R}^{m \times (m-1)}$ de forma que $V = [x \mid V_2] \in \mathbb{R}^{n \times n}$ e $U = [y \mid U_2] \in \mathbb{R}^{m \times m}$ sejam ortogonais. Podemos, então escrever

$$U^T A V = \begin{bmatrix} y^T \\ U_2^T \end{bmatrix} A \begin{bmatrix} x \mid V_2 \end{bmatrix} = \begin{bmatrix} \sigma & w^T \\ 0 & B \end{bmatrix}$$



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$. Do teorema 2 sabemos que existe $V_2 \in \mathbb{R}^{n \times (n-1)}$ e $U_2 \in \mathbb{R}^{m \times (m-1)}$ de forma que $V = [x \mid V_2] \in \mathbb{R}^{n \times n}$ e $U = [y \mid U_2] \in \mathbb{R}^{m \times m}$ sejam ortogonais. Podemos, então escrever

$$U^T A V = \begin{bmatrix} y^T \\ U_2^T \end{bmatrix} A \begin{bmatrix} x \mid V_2 \end{bmatrix} = \begin{bmatrix} \sigma & w^T \\ 0 & B \end{bmatrix} \equiv A_1$$



Decomposição em valores singulares

Agora, vamos à demonstração do **Teorema 1 (SVD)**.

- **Dem:** Sejam $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$ dois vetores tais que $\|x\|_2 = \|y\|_2 = 1$, e que satisfaçam $Ax = \sigma y$ com $\sigma = \|A\|_2$. Do teorema 2 sabemos que existe $V_2 \in \mathbb{R}^{n \times (n-1)}$ e $U_2 \in \mathbb{R}^{m \times (m-1)}$ de forma que $V = [x \mid V_2] \in \mathbb{R}^{n \times n}$ e $U = [y \mid U_2] \in \mathbb{R}^{m \times m}$ sejam ortogonais. Podemos, então escrever

$$U^T A V = \begin{bmatrix} y^T \\ U_2^T \end{bmatrix} A [x \mid V_2] = \begin{bmatrix} \sigma & w^T \\ 0 & B \end{bmatrix} \equiv A_1$$

onde $w \in \mathbb{R}^{n-1}$ e $B \in \mathbb{R}^{(m-1) \times (n-1)}$.



- Dem cont.: Como



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2$$

- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$.

- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$,



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$.



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$. Aplicando esse passo recursivamente à matriz B , teremos



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$. Aplicando esse passo recursivamente à matriz B , teremos

$$U^T A V$$



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$. Aplicando esse passo recursivamente à matriz B , teremos

$$U^T A V = \left[\begin{array}{c|cc} \sigma_1 & 0 & 0 \\ \hline 0 & \sigma_2 & w_2^T \\ 0 & 0 & B_2 \end{array} \right]$$



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$. Aplicando esse passo recursivamente à matriz B , teremos

$$U^T A V = \left[\begin{array}{c|cc} \sigma_1 & 0 & 0 \\ \hline 0 & \sigma_2 & w_2^T \\ 0 & 0 & B_2 \end{array} \right] \equiv A_2$$



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$. Aplicando esse passo recursivamente à matriz B , teremos

$$U^T A V = \left[\begin{array}{c|cc} \sigma_1 & 0 & 0 \\ \hline 0 & \sigma_2 & w_2^T \\ 0 & 0 & B_2 \end{array} \right] \equiv A_2$$

onde $w_2 \in \mathbb{R}^{n-2}$ e $B_2 \in \mathbb{R}^{(m-2) \times (n-2)}$.



- **Dem cont.:** Como

$$\left\| A_1 \begin{pmatrix} \sigma \\ w \end{pmatrix} \right\|_2^2 \geq (\sigma^2 + w^T w)^2$$

teremos que $\|A_1\|_2^2 \geq (\sigma^2 + w^T w)^2$. Mas pela definição, sabemos que $\sigma = \|A\|_2$, então $\sigma^2 = \|A\|_2^2 = \|A_1\|_2^2$ e para isso ser verdade, temos que $w = 0$. Aplicando esse passo recursivamente à matriz B , teremos

$$U^T A V = \left[\begin{array}{c|cc} \sigma_1 & 0 & 0 \\ \hline 0 & \sigma_2 & w_2^T \\ 0 & 0 & B_2 \end{array} \right] \equiv A_2$$

onde $w_2 \in \mathbb{R}^{n-2}$ e $B_2 \in \mathbb{R}^{(m-2) \times (n-2)}$. Com isso podemos ver que, recursivamente, a prova do teorema está completa. ■



Decomposição em valores singulares

$$A = U\Sigma V^T$$

=



Decomposição em valores singulares

$$A = U\Sigma V^T$$

$$\underbrace{A}_{m \times n} =$$



Decomposição em valores singulares

$$A = U\Sigma V^T$$

$$\underbrace{A}_{m \times n} = \underbrace{\begin{bmatrix} u_1 & \cdots & u_p & \cdots & u_m \end{bmatrix}}_{m \times m}$$

Decomposição em valores singulares

$$A = U\Sigma V^T$$

$$\underbrace{A}_{m \times n} = \underbrace{\begin{bmatrix} u_1 & \cdots & u_p & \cdots & u_m \end{bmatrix}}_{m \times m} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_p & \cdots & 0 \\ 0 & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 0 \end{bmatrix}}_{m \times n}$$

Decomposição em valores singulares

$$A = U\Sigma V^T$$

$$\underbrace{A}_{m \times n} = \underbrace{\begin{bmatrix} u_1 & \cdots & u_p & \cdots & u_m \end{bmatrix}}_{m \times m} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_p & \cdots & 0 \\ 0 & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 0 \end{bmatrix}}_{m \times n} \underbrace{\begin{bmatrix} v_1^T \\ \vdots \\ v_p^T \\ \vdots \\ v_n^T \end{bmatrix}}_{n \times n}$$



Decomposição em valores singulares

- σ_i são os valores singulares de A .



Decomposição em valores singulares

- σ_i são os valores singulares de A .
 - ▶ As seguintes notações podem ser usadas para denotar valores singulares de um determinada matriz A

$$\sigma_{\max}(A) = \sigma_1(A) \geq \sigma_2(A) \dots \geq \sigma_p(A) = \sigma_{\min}(A)$$

- As colunas de U são ortonormais, e u_i são os vetores singulares à esquerda de A .



Decomposição em valores singulares

- σ_i são os valores singulares de A .
 - ▶ As seguintes notações podem ser usadas para denotar valores singulares de um determinada matriz A

$$\sigma_{\max}(A) = \sigma_1(A) \geq \sigma_2(A) \dots \geq \sigma_p(A) = \sigma_{\min}(A)$$

- As colunas de U são ortonormais, e u_i são os vetores singulares à esquerda de A .
- As colunas de V são ortonormais, e v_i são os vetores singulares à direita de A .



Decomposição em valores singulares

- σ_i são os valores singulares de A .
 - ▶ As seguintes notações podem ser usadas para denotar valores singulares de um determinada matriz A

$$\sigma_{\max}(A) = \sigma_1(A) \geq \sigma_2(A) \dots \geq \sigma_p(A) = \sigma_{\min}(A)$$

- As colunas de U são ortonormais, e u_i são os vetores singulares à esquerda de A .
- As colunas de V são ortonormais, e v_i são os vetores singulares à direita de A .
- U e V não são únicos, no entanto Σ é único.



Propriedades

- Se $U^T A V = \Sigma$ é uma decomposição em valores singulares de $A \in \mathbb{R}^{m \times n}$ e $m \geq n$, então para $i = 1 : n$

$$A v_i = \sigma_i u_i \quad \text{e} \quad A^T u_i = \sigma_i v_i .$$

► Demonstração: Exercício



Propriedades

1. Considere



Propriedades

1. Considere

$$A^T A$$



Propriedades

1. Considere

$$A^T A = (U \Sigma V^T)^T (U \Sigma V^T)$$



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_{I} \Sigma V^T \end{aligned}$$



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_I \Sigma V^T \\ &= V \Sigma^2 V^T, \end{aligned}$$



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_I \Sigma V^T \\ &= V \Sigma^2 V^T, \end{aligned}$$

mas está é a decomposição de valores singulares de $A^T A$.



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_I \Sigma V^T \\ &= V \Sigma^2 V^T, \end{aligned}$$

mas está é a decomposição de valores singulares de $A^T A$. Então V é a matriz de autovetores de $A^T A$.



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_I \Sigma V^T \\ &= V \Sigma^2 V^T, \end{aligned}$$

mas está é a decomposição de valores singulares de $A^T A$. Então V é a matriz de autovetores de $A^T A$. Σ^2 é a matriz de autovalores de $A^T A$,



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_I \Sigma V^T \\ &= V \Sigma^2 V^T, \end{aligned}$$

mas está é a decomposição de valores singulares de $A^T A$. Então V é a matriz de autovetores de $A^T A$. Σ^2 é a matriz de autovalores de $A^T A$, isto é, os valores singulares A são as raízes quadradas dos autovalores não nulos de $A^T A$.



Propriedades

1. Considere

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) \\ &= V \Sigma^T \underbrace{U^T U}_I \Sigma V^T \\ &= V \Sigma^2 V^T, \end{aligned}$$

mas está é a decomposição de valores singulares de $A^T A$. Então V é a matriz de autovetores de $A^T A$. Σ^2 é a matriz de autovalores de $A^T A$, isto é, os valores singulares A são as raízes quadradas dos autovalores não nulos de $A^T A$.

$$\Sigma^T \Sigma = \left[\begin{array}{cccc|c} \sigma_1^2 & 0 & \cdots & 0 & 0 \\ 0 & \sigma_2^2 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & 0 \\ 0 & 0 & \cdots & \sigma_p^2 & 0 \\ \hline 0 & 0 & 0 & 0 & 0 \end{array} \right]$$



Propriedades

2. Similarmente, considere



Propriedades

2. Similarmente, considere

$$AA^T$$



Propriedades

2. Similarmente, considere

$$AA^T = (U\Sigma V^T) (U\Sigma V^T)^T$$



Propriedades

2. Similarmente, considere

$$\begin{aligned} AA^T &= (U\Sigma V^T) (U\Sigma V^T)^T \\ &= U\Sigma \underbrace{V^T V}_I \Sigma U^T \end{aligned}$$



Propriedades

2. Similarmente, considere

$$\begin{aligned} AA^T &= (U\Sigma V^T) (U\Sigma V^T)^T \\ &= U\Sigma \underbrace{V^T V}_I \Sigma U^T \\ &= U\Sigma^2 U^T, \end{aligned}$$



Propriedades

2. Similarmente, considere

$$\begin{aligned} AA^T &= (U\Sigma V^T) (U\Sigma V^T)^T \\ &= U\Sigma \underbrace{V^T V}_I \Sigma U^T \\ &= U\Sigma^2 U^T, \end{aligned}$$

mas está é a decomposição de valores singulares de AA^T .



Propriedades

2. Similarmente, considere

$$\begin{aligned} AA^T &= (U\Sigma V^T) (U\Sigma V^T)^T \\ &= U\Sigma \underbrace{V^T V}_I \Sigma U^T \\ &= U\Sigma^2 U^T, \end{aligned}$$

mas está é a decomposição de valores singulares de AA^T . Então U é a matriz de autovetores de AA^T .



Propriedades

2. Similarmente, considere

$$\begin{aligned} AA^T &= (U\Sigma V^T) (U\Sigma V^T)^T \\ &= U\Sigma \underbrace{V^T V}_I \Sigma U^T \\ &= U\Sigma^2 U^T, \end{aligned}$$

mas está é a decomposição de valores singulares de AA^T . Então U é a matriz de autovetores de AA^T . Σ^2 é a matriz de autovalores de AA^T ,



Propriedades

2. Similarmente, considere

$$\begin{aligned} AA^T &= (U\Sigma V^T) (U\Sigma V^T)^T \\ &= U\Sigma \underbrace{V^T V}_I \Sigma U^T \\ &= U\Sigma^2 U^T, \end{aligned}$$

mas está é a decomposição de valores singulares de AA^T . Então U é a matriz de autovetores de AA^T . Σ^2 é a matriz de autovalores de AA^T , ou seja, os valores singulares A são as raízes quadradas dos autovalores não nulos de AA^T .



Propriedades

Se $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ então

1. $\underbrace{\text{rank}(A)}_{\text{posto}} = r$



Propriedades

Se $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ então

1. $\underbrace{\text{rank}(A)}_{\text{posto}} = r$

2. $\underbrace{\text{null}(A)}_{\text{núcleo}} = \text{span}\{v_{r+1}, v_{r+2}, \dots v_n\}$



Propriedades

Se $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ então

1. $\underbrace{\text{rank}(A)}_{\text{posto}} = r$

2. $\underbrace{\text{null}(A)}_{\text{núcleo}} = \text{span}\{v_{r+1}, v_{r+2}, \dots v_n\}$

3. $\underbrace{\text{range}(A)}_{\text{imagem}} = \text{span}\{u_1, u_2, \dots u_r\}$



Propriedades

Se $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ então

1. $\underbrace{\text{rank}(A)}_{\text{posto}} = r$

2. $\underbrace{\text{null}(A)}_{\text{núcleo}} = \text{span}\{v_{r+1}, v_{r+2}, \dots v_n\}$

3. $\underbrace{\text{range}(A)}_{\text{imagem}} = \text{span}\{u_1, u_2, \dots u_r\}$

4. $A = \sum_{i=1}^r \sigma_i u_i v_i^T$



Propriedades

Se $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ então

1. $\underbrace{\text{rank}(A)}_{\text{posto}} = r$

2. $\underbrace{\text{null}(A)}_{\text{núcleo}} = \text{span}\{v_{r+1}, v_{r+2}, \dots v_n\}$

3. $\underbrace{\text{range}(A)}_{\text{imagem}} = \text{span}\{u_1, u_2, \dots u_r\}$

4. $A = \sum_{i=1}^r \sigma_i u_i v_i^T$

5. $\|A\|_2 = \sigma_1$



Propriedades

Se $\sigma_1 \geq \sigma_2 \geq \dots \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$ então

1. $\underbrace{\text{rank}(A)}_{\text{posto}} = r$

2. $\underbrace{\text{null}(A)}_{\text{núcleo}} = \text{span}\{v_{r+1}, v_{r+2}, \dots v_n\}$

3. $\underbrace{\text{range}(A)}_{\text{imagem}} = \text{span}\{u_1, u_2, \dots u_r\}$

4. $A = \sum_{i=1}^r \sigma_i u_i v_i^T$

5. $\|A\|_2 = \sigma_1$

6. $\|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_p^2}$, onde $p = \min\{m, n\}$



Exemplo

Seja

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ -2 & 2 \end{bmatrix} \quad \text{e} \quad A^T = \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix}$$

Exemplo

Seja

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ -2 & 2 \end{bmatrix} \quad \text{e} \quad A^T = \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix}$$

Então

$$AA^T = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 8 \end{bmatrix}$$

Exemplo

Seja

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ -2 & 2 \end{bmatrix} \quad \text{e} \quad A^T = \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix}$$

Então

$$AA^T = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 8 \end{bmatrix}$$

Os autovalores são raízes da equação $\det(AA^T - \lambda I) = 0$, isto é,



Exemplo

Seja

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ -2 & 2 \end{bmatrix} \quad \text{e} \quad A^T = \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix}$$

Então

$$AA^T = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 8 \end{bmatrix}$$

Os autovalores são raízes da equação $\det(AA^T - \lambda I) = 0$, isto é,

$$\det = \begin{vmatrix} 2 - \lambda & 0 & 0 \\ 0 & -\lambda & 0 \\ 0 & 0 & 8 - \lambda \end{vmatrix} = 0$$



Exemplo

Seja

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ -2 & 2 \end{bmatrix} \quad \text{e} \quad A^T = \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix}$$

Então

$$AA^T = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 8 \end{bmatrix}$$

Os autovalores são raízes da equação $\det(AA^T - \lambda I) = 0$, isto é,

$$\det = \begin{vmatrix} 2 - \lambda & 0 & 0 \\ 0 & -\lambda & 0 \\ 0 & 0 & 8 - \lambda \end{vmatrix} = 0$$

Resolvendo, obtemos as raízes $\lambda_1 = 8$, $\lambda_2 = 2$ e $\lambda_3 = 0$.



Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$.



Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$. Portanto, a matriz Σ é dada por



Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$. Portanto, a matriz Σ é dada por

$$\Sigma = \begin{bmatrix} \sqrt{8} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$. Portanto, a matriz Σ é dada por

$$\Sigma = \begin{bmatrix} \sqrt{8} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

Vamos calcular os autovetores associados aos três autovalores.

Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$. Portanto, a matriz Σ é dada por

$$\Sigma = \begin{bmatrix} \sqrt{8} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

Vamos calcular os autovetores associados aos três autovalores. Para $\lambda_1 = 8$, temos

$$\begin{bmatrix} 2-8 & 0 & 0 \\ 0 & -8 & 0 \\ 0 & 0 & 8-8 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$. Portanto, a matriz Σ é dada por

$$\Sigma = \begin{bmatrix} \sqrt{8} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

Vamos calcular os autovetores associados aos três autovalores. Para $\lambda_1 = 8$, temos

$$\begin{bmatrix} 2-8 & 0 & 0 \\ 0 & -8 & 0 \\ 0 & 0 & 8-8 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Resolvendo e tomando $z = 1$, temos que $x = y = 0$.



Exemplo cont.

Logo, os valores singulares não nulos de A são $\sigma_1 = \sqrt{\lambda_1} = \sqrt{8}$ e $\sigma_2 = \sqrt{\lambda_2} = \sqrt{2}$. Portanto, a matriz Σ é dada por

$$\Sigma = \begin{bmatrix} \sqrt{8} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix}$$

Vamos calcular os autovetores associados aos três autovalores. Para $\lambda_1 = 8$, temos

$$\begin{bmatrix} 2-8 & 0 & 0 \\ 0 & -8 & 0 \\ 0 & 0 & 8-8 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Resolvendo e tomando $z = 1$, temos que $x = y = 0$. Logo,

$$u_1 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$



Exemplo cont.

Para $\lambda_2 = 2$, temos

$$\begin{bmatrix} 2-2 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 8-2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Exemplo cont.

Para $\lambda_2 = 2$, temos

$$\begin{bmatrix} 2-2 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 8-2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Resolvendo e tomando $x = -1$, temos que $z = y = 0$. Logo,

$$u_2 = \begin{bmatrix} -1 \\ 0 \\ 0 \end{bmatrix}$$



Exemplo cont.

Para $\lambda_3 = 0$, temos

$$\begin{bmatrix} 2-0 & 0 & 0 \\ 0 & -0 & 0 \\ 0 & 0 & 8-0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Exemplo cont.

Para $\lambda_3 = 0$, temos

$$\begin{bmatrix} 2-0 & 0 & 0 \\ 0 & -0 & 0 \\ 0 & 0 & 8-0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Resolvendo e tomando $y = -1$, temos que $z = x = 0$. Logo,

$$u_3 = \begin{bmatrix} 0 \\ -1 \\ 0 \end{bmatrix}$$



Exemplo cont.

Como $\|u_1\| = \|u_2\| = \|u_3\| = 1$,



Exemplo cont.

Como $\|u_1\| = \|u_2\| = \|u_3\| = 1$, a matriz U de A será

$$U = \left[\frac{u_1}{\|u_1\|} \mid \frac{u_2}{\|u_2\|} \mid \frac{u_3}{\|u_3\|} \right] = \begin{bmatrix} 0 & -1 & 0 \\ 0 & 0 & -1 \\ 1 & 0 & 0 \end{bmatrix}$$



Exemplo cont.

Como $\|u_1\| = \|u_2\| = \|u_3\| = 1$, a matriz U de A será

$$U = \left[\frac{u_1}{\|u_1\|} \mid \frac{u_2}{\|u_2\|} \mid \frac{u_3}{\|u_3\|} \right] = \begin{bmatrix} 0 & -1 & 0 \\ 0 & 0 & -1 \\ 1 & 0 & 0 \end{bmatrix}$$

Para encontrar a matriz V , usamos o fato que $v_i = \frac{1}{\sigma_i} A^T u_i$.



Exemplo cont.

Como $\|u_1\| = \|u_2\| = \|u_3\| = 1$, a matriz U de A será

$$U = \left[\frac{u_1}{\|u_1\|} \mid \frac{u_2}{\|u_2\|} \mid \frac{u_3}{\|u_3\|} \right] = \begin{bmatrix} 0 & -1 & 0 \\ 0 & 0 & -1 \\ 1 & 0 & 0 \end{bmatrix}$$

Para encontrar a matriz V , usamos o fato que $v_i = \frac{1}{\sigma_i} A^T u_i$. Logo, v_1 será

$$v_1 = \frac{1}{\sigma_1} A^T u_1 = \frac{1}{\sqrt{8}} \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{-\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix}$$



Exemplo cont.

Para, v_2 será

$$v_2 = \frac{2}{\sigma_2} A^T u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{-\sqrt{2}}{2} \\ \frac{-\sqrt{2}}{2} \end{bmatrix}$$

Exemplo cont.

Para, v_2 será

$$v_2 = \frac{2}{\sigma_2} A^T u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{-\sqrt{2}}{2} \\ \frac{-\sqrt{2}}{2} \end{bmatrix}$$

Segue que

$$V = \begin{bmatrix} \frac{-\sqrt{2}}{2} & \frac{-\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{-\sqrt{2}}{2} \end{bmatrix}$$

Exemplo cont.

Para, v_2 será

$$v_2 = \frac{2}{\sigma_2} A^T u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & -2 \\ 1 & 0 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{-\sqrt{2}}{2} \\ \frac{-\sqrt{2}}{2} \end{bmatrix}$$

Segue que

$$V = \begin{bmatrix} \frac{-\sqrt{2}}{2} & \frac{-\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{-\sqrt{2}}{2} \end{bmatrix}$$

Logo,

$$A = U \Sigma V^T = \begin{bmatrix} 0 & -1 & 0 \\ 0 & 0 & -1 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} \sqrt{8} & 0 \\ 0 & \sqrt{2} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{-\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{-\sqrt{2}}{2} & \frac{-\sqrt{2}}{2} \end{bmatrix}$$

