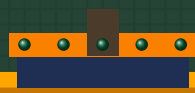
Métodos Matriciais Computacionais

Problemas de autovalores:
Teoria da Pertubação. Método da Iteração da Potência

Prof.ª Cibele Aparecida Ladeia





Teoria da pertubação

- Assim como o problema de resolver um sistema de equações lineares $Ax = b$ pode ser sensível a perturbações nos dados,

Teoria da pertubação

- Assim como o problema de resolver um sistema de equações lineares $Ax = b$ pode ser sensível a perturbações nos dados,
- o problema de calcular autovalores de uma matriz também pode ser sensível a perturbações na matriz.

Teoria da pertubação

- Assim como o problema de resolver um sistema de equações lineares $Ax = b$ pode ser sensível a perturbações nos dados,
- o problema de calcular autovalores de uma matriz também pode ser sensível a perturbações na matriz.
- Vamos agora obter alguns resultados relativos a extensão dessa sensibilidade.

Teoria da pertubação

Teorema 1 (Teorema do círculo de Gershgorin):

Seja $A \in \mathbb{C}^{n\times n}$, e seja $\lambda \in \lambda(A)$. Então λ encontra-se dentro da união dos discos de Gershgorin

$$|\lambda - a_{ii}| \leq \sum_{j=1, j\neq i}^{n} |a_{ij}|, \quad i = 1, 2, \ldots, n$$

Teoria da pertubação

Exemplo 1: Os autovalores da matriz

$$A = \begin{bmatrix} -5 & -1 & 1 \\ -2 & 2 & -1 \\ 1 & -3 & 7 \end{bmatrix}$$

são $\lambda(A) = \{6.4971,\ 2.7930,\ -5.2902\}$.

Exemplo 1: Os autovalores da matriz

$$A = \begin{bmatrix} -5 & -1 & 1 \\ -2 & 2 & -1 \\ 1 & -3 & 7 \end{bmatrix}$$

são $\lambda(A) = \{6.4971,\ 2.7930,\ -5.2902\}$. Os disco de Gershgorin são

$$D_1 = \{z \in \mathbb{C} : |z-7| \leq 4\},$$
$$D_2 = \{z \in \mathbb{C} : |z-2| \leq 3\},$$
$$D_3 = \{z \in \mathbb{C} : |z+5| \leq 2\},$$

Vemos que cada discos contém um autovalor.

Teoria da pertubação

- É importante observar que, embora existam n autovalores e n discos de Gershgorin, não é necessariamente verdade que cada disco contém um autovalor.

Teoria da pertubação

- É importante observar que, embora existam n autovalores e n discos de Gershgorin, não é necessariamente verdade que cada disco contém um autovalor.
- O teorema do círculo de Gershgorin afirma apenas que todos os autovalores estão contidos em a união dos discos.

Teoria da pertubação

Número de condição de um autovalor simples

- Seria desejável ter uma medida concreta da sensibilidade de um autovalor, assim como temos o número de condição que mede a sensibilidade de um sistema de equações lineares.

Número de condição de um autovalor simples

- Seria desejável ter uma medida concreta da sensibilidade de um autovalor, assim como temos o número de condição que mede a sensibilidade de um sistema de equações lineares.
- Para esse fim, assumimos que λ é um autovalor simples de $A \in \mathbb{C}^{n\times n}$, com autovetor à direita x e autovetor à esquerda y.

Teoria da pertubação

Número de condição de um autovalor simples

- Seria desejável ter uma medida concreta da sensibilidade de um autovalor, assim como temos o número de condição que mede a sensibilidade de um sistema de equações lineares.
- Para esse fim, assumimos que λ é um autovalor simples de $A \in \mathbb{C}^{n\times n}$, com autovetor à direita x e autovetor à esquerda y.
- Do fato que λ é um autovalor simples, temos que $\text{rank}(A - \lambda I) = n - 1$.

Número de condição de um autovalor simples

- Como y é um autovetor de A^H com autovalor $\overline{\lambda}$, y é ortogonal a range$(A - \lambda I)$. Isto é,

  $$(\text{range}(A - \lambda I))^{\perp} = \text{null}((A - \lambda I)^H) = \text{null}(A^H - \overline{\lambda} I) = \text{span}\{y\}.$$

Número de condição de um autovalor simples

- Como y é um autovetor de A^H com autovalor $\overline{\lambda}$, y é ortogonal a range$(A - \lambda I)$. Isto é,

  $$(\text{range}(A - \lambda I))^{\perp} = \text{null}((A - \lambda I)^H) = \text{null}(A^H - \overline{\lambda} I) = \text{span}\{y\}.$$

- Portanto, y não pode ser ortogonal a x, que gera null$(A - \lambda I)$ sem ser o vetor zero, o que contradiz a suposição de que y é um autovetor esquerdo.





Número de condição de um autovalor simples

- Como y é um autovetor de A^H com autovalor $\overline{\lambda}$, y é ortogonal a range$(A - \lambda I)$. Isto é,

  $$(\text{range}(A - \lambda I))^{\perp} = \text{null}((A - \lambda I)^H) = \text{null}(A^H - \overline{\lambda} I) = \text{span}\{y\}.$$

- Portanto, y não pode ser ortogonal a x, que gera null$(A - \lambda I)$ sem ser o vetor zero, o que contradiz a suposição de que y é um autovetor esquerdo.
- Segue que $y^H x \neq 0$. Portanto, podemos assumir que x e y são normalizados para que $y^H x = 1$.



Número de condição de um autovalor simples

- Agora, sejam A, λ e x funções de um parâmetro ϵ que satisfaz

$$A(\epsilon)x(\epsilon) = \lambda(\epsilon)x(\epsilon), \quad A(\epsilon) = A + \epsilon F, \quad \|F\|_2 = 1$$





Número de condição de um autovalor simples

- Agora, sejam A, λ e x funções de um parâmetro ϵ que satisfaz

$$A(\epsilon)x(\epsilon) = \lambda(\epsilon)x(\epsilon), \quad A(\epsilon) = A + \epsilon F, \quad \|F\|_2 = 1$$

- Diferenciando com relação a ϵ, e avaliando em $\epsilon = 0$, temos

$$Fx + Ax'(0) = \lambda x'(0) + \lambda'(0)x$$



Número de condição de um autovalor simples

- Agora, sejam A, λ e x funções de um parâmetro ϵ que satisfaz

$$A(\epsilon)x(\epsilon) = \lambda(\epsilon)x(\epsilon), \quad A(\epsilon) = A + \epsilon F, \quad \|F\|_2 = 1$$

- Diferenciando com relação a ϵ, e avaliando em $\epsilon = 0$, temos

$$Fx + Ax'(0) = \lambda x'(0) + \lambda'(0)x$$

- Tomando o produto interno de ambos os lados da equação com y^H e simplificando segue que

$$y^H Fx + y^H Ax'(0) = \lambda y^H x'(0) + \lambda'(0) y^H x$$

Número de condição de um autovalor simples

- Como y é um autovetor à esquerda correspondendo a λ, e $y^H x = 1$, temos

$$y^H F x + \lambda y^H x'(0) = \lambda y^H x'(0) + \lambda'(0)$$

Número de condição de um autovalor simples

- Como y é um autovetor à esquerda correspondendo a λ, e $y^H x = 1$, temos

$$y^H F x + \lambda y^H x'(0) = \lambda y^H x'(0) + \lambda'(0)$$

- Concluímos que

$$|\lambda'(0)| = |y^H F x| \leq \|y\|_2 \|Fx\|_2 \leq \|y\|_2 \|F\|_2 \|x\|_2 \leq \|y\|_2 \|x\|_2$$

- Como θ, o ângulo entre x e y, é dado por

$$\cos\theta = \frac{y^H x}{\|y\|_2 \|x\|_2} = \frac{1}{\|y\|_2 \|x\|_2}$$



Número de condição de um autovalor simples

- Como y é um autovetor à esquerda correspondendo a λ, e $y^H x = 1$, temos

$$y^H F x + \lambda y^H x'(0) = \lambda y^H x'(0) + \lambda'(0)$$

- Concluímos que

$$|\lambda'(0)| = |y^H F x| \leq \|y\|_2 \|Fx\|_2 \leq \|y\|_2 \|F\|_2 \|x\|_2 \leq \|y\|_2 \|x\|_2$$

- Como θ, o ângulo entre x e y, é dado por

$$\cos\theta = \frac{y^H x}{\|y\|_2 \|x\|_2} = \frac{1}{\|y\|_2 \|x\|_2}$$



Número de condição de um autovalor simples

- Segue que

$$|\lambda'(0)| \leq \frac{1}{|\cos\theta|}$$

Número de condição de um autovalor simples

- Segue que

$$|\lambda'(0)| \leq \frac{1}{|\cos\theta|}$$

- Definimos $\frac{1}{|\cos\theta|}$ o <u>número de condição</u> de um autovalor simples λ.

Número de condição de um autovalor simples

- Segue que

$$|\lambda'(0)| \leq \frac{1}{|\cos\theta|}$$

- Definimos $\frac{1}{|\cos\theta|}$ o número de condição de um autovalor simples λ.
- A hipótese de λ simples é necessária, pois, no caso de autovalores múltiplos, os autovetores esquerda e direita não são únicos e o ângulo entre eles deixa de ser unicamente definido.

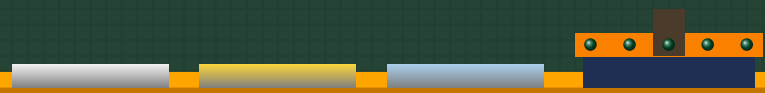
Número de condição de um autovalor simples

- A interpretação do número de condição é que uma perturbação $O(\epsilon)$ em A pode causar uma perturbação $O(\epsilon/|\cos\theta|)$ no autovalor.

Número de condição de um autovalor simples

- A interpretação do número de condição é que uma perturbação $O(\epsilon)$ em A pode causar uma perturbação $O(\epsilon/|\cos\theta|)$ no autovalor.
- Portanto, se x e y forem quase ortogonais, uma grande mudança no autovalor pode ocorrer.





Número de condição de um autovalor simples

- A interpretação do número de condição é que uma perturbação $O(\epsilon)$ em A pode causar uma perturbação $O(\epsilon/|\cos\theta|)$ no autovalor.
- Portanto, se x e y forem quase ortogonais, uma grande mudança no autovalor pode ocorrer.
- Além disso, se o número de condição for grande, então A está perto de uma matriz com um autovalor múltiplo.



Número de condição de um autovalor simples

Exemplo 2: A matriz

$$A = \begin{bmatrix} 3.1482 & -0.2017 & -0.5363 \\ 0.4196 & 0.5171 & 1.0888 \\ 0.3658 & -1.7169 & 3.3361 \end{bmatrix}$$

tem um autovalor simples $\lambda = 1.9833$ com autovetores à esquerda e à direita

$$x = \begin{bmatrix} 0.4150 \\ 0.6160 \\ 0.6696 \end{bmatrix}, \quad y = \begin{bmatrix} -7.9435 \\ 83.0701 \\ -70.0066 \end{bmatrix}$$

tal que, $y^H x = 1$.

Número de condição de um autovalor simples

Exemplo 2: A matriz

$$A = \begin{bmatrix} 3.1482 & -0.2017 & -0.5363 \\ 0.4196 & 0.5171 & 1.0888 \\ 0.3658 & -1.7169 & 3.3361 \end{bmatrix}$$

tem um autovalor simples $\lambda = 1.9833$ com autovetores à esquerda e à direita

$$x = \begin{bmatrix} 0.4150 \\ 0.6160 \\ 0.6696 \end{bmatrix}, \quad y = \begin{bmatrix} -7.9435 \\ 83.0701 \\ -70.0066 \end{bmatrix}$$

tal que, $y^H x = 1$.Segue que o número de condição deste autovalor é $\|x\|_2 \|y\|_2 = 108.925$.

Número de condição de um autovalor simples

Exemplo 2: continuação De fato, a matriz próxima

$$B = \begin{bmatrix} 3.1477 & -0.2023 & -0.5366 \\ 0.4187 & 0.5169 & 1.0883 \\ 0.3654 & -1.7176 & 3.3354 \end{bmatrix}$$

tem um autovalor duplo igual a 2.



Sensibilidade de autovalores repetidos

- Agora, consideramos a sensibilidade de autovalores repetidos.

Sensibilidade de autovalores repetidos

- Agora, consideramos a sensibilidade de autovalores repetidos.
- Primeiro, é importante notar que, embora os autovalores de uma matriz A sejam funções contínuas das entradas de A, eles não são necessariamente diferenciáveis.

Sensibilidade de autovalores repetidos

- Agora, consideramos a sensibilidade de autovalores repetidos.
- Primeiro, é importante notar que, embora os autovalores de uma matriz A sejam funções contínuas das entradas de A, eles não são necessariamente diferenciáveis.
- Para ver isso, consideramos a matriz,

$$A = \begin{bmatrix} 1 & a \\ \epsilon & 1 \end{bmatrix},$$

onde $a > 0$.

Sensibilidade de autovalores repetidos

- Agora, consideramos a sensibilidade de autovalores repetidos.
- Primeiro, é importante notar que, embora os autovalores de uma matriz A sejam funções contínuas das entradas de A, eles não são necessariamente diferenciáveis.
- Para ver isso, consideramos a matriz,

$$A = \begin{bmatrix} 1 & a \\ \epsilon & 1 \end{bmatrix},$$

onde $a > 0$.

- Calculando o polinômio característico

$$\det(A - \lambda I) = \lambda^2 - 2\lambda + 1 - a\epsilon$$

e calculando as raízes obtemos autovalores $\lambda = 1 \pm \sqrt{a\epsilon}$.

Sensibilidade de autovalores repetidos

- Diferenciando estes autovalores com respeito a ϵ temos

$$\frac{d\lambda}{d\epsilon} = \pm\frac{1}{2}\sqrt{\frac{a}{\epsilon}}$$

no qual é indefinido em $\epsilon = 0$.

Sensibilidade de autovalores repetidos

- Diferenciando estes autovalores com respeito a ϵ temos

$$\frac{d\lambda}{d\epsilon} = \pm\frac{1}{2}\sqrt{\frac{a}{\epsilon}}$$

  no qual é indefinido em $\epsilon = 0$.
- Em geral, uma pertubação $O(\epsilon)$ em A causa uma pertubação $O(\epsilon^{1/p})$ nos autovalores associados com um bloco de Jordan $p \times p$, o que significa que quanto mais defeituoso for um autovalor, mais sensível é.



Sensibilidade do subespaço invariante

- Agora, consideramos a sensibilidade dos autovalores, ou mais geralmente, subespaços invariantes de uma matriz A, como um subespaço estendido pelos primeiros k vetores de Schur, que são as primeiras k colunas em uma matriz Q tal que, $Q^H A Q$ é triangular superior.

Sensibilidade do subespaço invariante

- Agora, consideramos a sensibilidade dos autovalores, ou mais geralmente, subespaços invariantes de uma matriz A, como um subespaço estendido pelos primeiros k vetores de Schur, que são as primeiras k colunas em uma matriz Q tal que, $Q^H A Q$ é triangular superior.
- Suponha que uma matriz A de ordem $n \times n$ tenha a decomposição de Schur

$$A = QTQ^H, \quad Q = \begin{bmatrix} Q_1 & Q_2 \end{bmatrix}, \quad T = \begin{bmatrix} T_{11} & T_{12} \\ 0 & T_{22} \end{bmatrix}$$

onde Q_1 é da ordem $n \times r$ e T_{11} é da ordem $r \times r$.

Sensibilidade do Subespaço Invariante

- Definimos a separação entre as matrizes T_{11} e T_{22} por

$$\text{sep}(T_{11}, T_{22}) = \min_{X \neq 0} \frac{\|T_{11}X - XT_{22}\|_F}{\|X\|_F}$$

Sensibilidade do Subespaço Invariante

- Definimos a separação entre as matrizes T_{11} e T_{22} por

$$\text{sep}(T_{11}, T_{22}) = \min_{X \neq 0} \frac{\|T_{11}X - XT_{22}\|_F}{\|X\|_F}$$

- Pode ser mostrado que uma perturbação $O(\epsilon)$ em A causa uma perturbação $O(\epsilon/\text{sep}(T_{11}, T_{22}))$ em um subespaço invariante Q_1.

Sensibilidade do Subespaço Invariante

- Definimos a separação entre as matrizes T_{11} e T_{22} por

$$\text{sep}(T_{11}, T_{22}) = \min_{X \neq 0} \frac{\|T_{11}X - XT_{22}\|_F}{\|X\|_F}$$

- Pode ser mostrado que uma perturbação $O(\epsilon)$ em A causa uma perturbação $O(\epsilon/\text{sep}(T_{11}, T_{22}))$ em um subespaço invariante Q_1.
- Agora, considere o caso onde $r = 1$, significa que Q_1 é na verdade um vetor q_1, que é também um autovetor, e T_{11} é o seu autovalor correspondente, λ.

Sensibilidade do Subespaço Invariante

- Então, temos

$$\begin{aligned}\text{sep}(\lambda, T_{22}) &= \min_{X \neq 0} \frac{\|\lambda X - X T_{22}\|_F}{\|X\|_F} \\ &= \min_{\|y\|_2 = 1} \|y^H (T_{22} - \lambda I)\|_2 \\ &= \min_{\|y\|_2 = 1} \|(T_{22} - \lambda I)^H y\|_2 \\ &= \sigma(T_{22} - \lambda I),\end{aligned}$$

visto que a norma de Frobenius de um vetor é igual à sua norma-2 de vetor.

Sensibilidade do Subespaço Invariante

- Como o menor valor singular indica a distância até uma matriz singular, $\mathrm{sep}(\lambda, T_{22})$ fornece uma medida da separação entre λ e os demais autovalores de A.

Sensibilidade do Subespaço Invariante

- Como o menor valor singular indica a distância até uma matriz singular, $\mathrm{sep}(\lambda, T_{22})$ fornece uma medida da separação entre λ e os demais autovalores de A.
- Segue-se que os autovetores são mais sensíveis a perturbações quando os autovalores correspondentes estão agrupados próximos uns dos outros.

Sensibilidade do Subespaço Invariante

- Como o menor valor singular indica a distância até uma matriz singular, $\mathrm{sep}(\lambda, T_{22})$ fornece uma medida da separação entre λ e os demais autovalores de A.
- Segue-se que os autovetores são mais sensíveis a perturbações quando os autovalores correspondentes estão agrupados próximos uns dos outros.
- Deve-se enfatizar que não há relação direta entre a sensibilidade de um autovalor e a sensibilidade do subespaço invariante correspondente.

Sensibilidade

- A sensibilidade de um autovalor simples depende do ângulo entre seus autovetores esquerdo e direito, enquanto a sensibilidade de um subespaço invariante depende do agrupamento dos autovalores.

Sensibilidade

- A sensibilidade de um autovalor simples depende do ângulo entre seus autovetores esquerdo e direito, enquanto a sensibilidade de um subespaço invariante depende do agrupamento dos autovalores.
- Portanto, um autovalor sensível, isto é, quase defeituoso, pode estar associado a um subespaço invariante pouco sensível, caso esteja bem separado dos demais autovalores. Por outro lado, um autovalor pouco sensível pode possuir um subespaço invariante sensível, caso esteja muito próximo de outros autovalores.

Método da Iteração da Potência

- Agora que temos uma compreensão do problema de autovalores, em termos de existência, singularidade e sensibilidade das soluções, podemos agora voltar nossa atenção para o desenvolvimento de algoritmos para a solução numérica de uma dada matriz quadrada A.

Método da Iteração da Potência

- Agora que temos uma compreensão do problema de autovalores, em termos de existência, singularidade e sensibilidade das soluções, podemos agora voltar nossa atenção para o desenvolvimento de algoritmos para a solução numérica de uma dada matriz quadrada A.
- Vimos que se pudermos calcular um único par de autovalor-autovetor de A, podemos usar a deflação para aproximar A da forma triangular.

Método da Iteração da Potência

- Agora que temos uma compreensão do problema de autovalores, em termos de existência, singularidade e sensibilidade das soluções, podemos agora voltar nossa atenção para o desenvolvimento de algoritmos para a solução numérica de uma dada matriz quadrada A.
- Vimos que se pudermos calcular um único par de autovalor-autovetor de A, podemos usar a deflação para aproximar A da forma triangular.
- Portanto, procuramos calcular esse par, conhecido como auto-par (eigenpair).

Método da Iteração da Potência

- Agora que temos uma compreensão do problema de autovalores, em termos de existência, singularidade e sensibilidade das soluções, podemos agora voltar nossa atenção para o desenvolvimento de algoritmos para a solução numérica de uma dada matriz quadrada A.
- Vimos que se pudermos calcular um único par de autovalor-autovetor de A, podemos usar a deflação para aproximar A da forma triangular.
- Portanto, procuramos calcular esse par, conhecido como auto-par (eigenpair).
- Vamos considerar que A é real.

Método da Iteração da Potência

- Por simplicidade, vamos assumir que A tem autovalores $\lambda_1, \lambda_2, \ldots, \lambda_n$, tal que

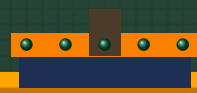
Método da Iteração da Potência

- Por simplicidade, vamos assumir que A tem autovalores $\lambda_1, \lambda_2, \ldots, \lambda_n$, tal que

$$|\lambda_1| > |\lambda_2| \geq \ldots \geq |\lambda_n|$$

- Também assumimos que A é diagonalizável, o que significa que tem n autovetores L.I., $x_1, x_2, \ldots, x_n$, tal que $Ax_i = \lambda_i x_i$ para $i = 1, \ldots, n$.





Método da Iteração da Potência

- Por simplicidade, vamos assumir que A tem autovalores $\lambda_1, \lambda_2, \ldots, \lambda_n$, tal que

$$|\lambda_1| > |\lambda_2| \geq \ldots \geq |\lambda_n|$$

- Também assumimos que A é diagonalizável, o que significa que tem n autovetores L.I., $x_1, x_2, \ldots, x_n$, tal que $Ax_i = \lambda_i x_i$ para $i = 1, \ldots, n$.
- Suponha que multipliquemos repetidamente um dado vetor diferente de zero $x^{(0)}$ por A, gerando uma sequência de vetores $x^{(1)}, x^{(2)}, \ldots$ definida por

$$x^{(k)} = Ax^{(k-1)} = A^k x^{(0)}, \quad k = 1, 2, \ldots$$

Método da Iteração da Potência

- Como A é diagonalizável, qualquer vetor em $\mathbb{R}^n$ é uma combinação linear dos autovetores, e portanto, podemos escrever

$$x^{(0)} = c_1 x_1 + c_2 x_2 + \ldots + c_n x_n$$

Método da Iteração da Potência

- Como A é diagonalizável, qualquer vetor em $\mathbb{R}^n$ é uma combinação linear dos autovetores, e portanto, podemos escrever

$$x^{(0)} = c_1 x_1 + c_2 x_2 + \ldots + c_n x_n$$

- Então, temos

$$\begin{aligned} x^{(k)} &= A^k x^{(0)} \\ &= \sum_{i=1}^{n} c_i A^k x_i \\ &= \sum_{i=1}^{n} c_i \lambda_i^k x_i \\ &= \lambda_1^k \left[c_1 x_1 + \sum_{i=2}^{n} c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k x_i \right] \end{aligned}$$

Método da Iteração da Potência

- Como $|\lambda_1| > |\lambda_i|$ para $i = 2, \ldots, n$, segue-se que se normalizarmos cada $x^{(k)}$, então os coeficientes de x_i, para $i = 2, \ldots, n$, convergem para zero quando $k \to \infty$.

Método da Iteração da Potência

- Como $|\lambda_1| > |\lambda_i|$ para $i = 2, \ldots, n$, segue-se que se normalizarmos cada $x^{(k)}$, então os coeficientes de x_i, para $i = 2, \ldots, n$, convergem para zero quando $k \to \infty$.
- Portanto, a direção de $x^{(k)}$ converge para a direção de x_1.

Método da Iteração da Potência

- Como $|\lambda_1| > |\lambda_i|$ para $i = 2, \ldots, n$, segue-se que se normalizarmos cada $x^{(k)}$, então os coeficientes de x_i, para $i = 2, \ldots, n$, convergem para zero quando $k \to \infty$.
- Portanto, a direção de $x^{(k)}$ converge para a direção de x_1.
- Isso leva ao método mais básico de calcular um autovalor e um autovetor, chamado de método da potência.

Algoritmo do Método da Potência

Dados: matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$, com $|\lambda_1| > |\lambda_2|$
Saída: cálculo do autovetor de A correspondente a λ_1.

1 Escolha um vetor inicial q_0 de modo que $\|q_0\|_2 = 1$
2 **para** $k = 1, 2, \ldots$ *até a convergência* **faça**
3 $\quad z_k = Aq_{k-1}$
4 $\quad q_k = z_k / \|z_k\|_2$

Algoritmo do Método da Potência

Dados: matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$, com $|\lambda_1| > |\lambda_2|$
Saída: cálculo do autovetor de A correspondente a λ_1.

1 Escolha um vetor inicial q_0 de modo que $\|q_0\|_2 = 1$
2 **para** $k = 1, 2, \ldots$ *até a convergência* **faça**
3 $\quad z_k = Aq_{k-1}$
4 $\quad q_k = z_k / \|z_k\|_2$

- O algoritmo é repetido até que q_k converja dentro de uma tolerância prescrita.
- Se houver convergência, o limite será um vetor unitário proporcional a x_1, autovetor associado ao autovalor dominante λ_1.
- A taxa de convergência é dada por $\left|\frac{\lambda_2}{\lambda_1}\right|$, o que significa que a distância entre os subespaços $\text{span}\{q_k\}$ e $\text{span}\{x_1\}$ decresce aproximadamente por esse fator a cada iteração.

Método da Iteração da Potência

- Conclui-se que a convergência pode ser lenta se λ_2 for quase tão grande quanto λ_1 e, de fato, o método da potência falha em convergir se $\lambda_2 = \lambda_1$, mas $\lambda_2 \neq \lambda_1$(por exemplo, se eles têm sinais opostos ou são complexos conjugados).

Método da Iteração da Potência

- Conclui-se que a convergência pode ser lenta se λ_2 for quase tão grande quanto λ_1 e, de fato, o método da potência falha em convergir se $\lambda_2 = \lambda_1$, mas $\lambda_2 \neq \lambda_1$(por exemplo, se eles têm sinais opostos ou são complexos conjugados).
- É importante notar um detalhe na implementação que se λ_1 for negativo, por exemplo, pode aparecer q_k fique alternado entre dois vetores.

Método da Iteração da Potência

- Conclui-se que a convergência pode ser lenta se λ_2 for quase tão grande quanto λ_1 e, de fato, o método da potência falha em convergir se $\lambda_2 = \lambda_1$, mas $\lambda_2 \neq \lambda_1$(por exemplo, se eles têm sinais opostos ou são complexos conjugados).
- É importante notar um detalhe na implementação que se λ_1 for negativo, por exemplo, pode aparecer q_k fique alternado entre dois vetores.
- Isso é remediado normalizando q_k de modo que não seja apenas um vetor unitário, mas também tenha, por exemplo, um primeira componente positiva.

Método da Iteração da Potência

- Uma vez que um autovetor x_1 é encontrado, o autovalor correspondente λ_1 pode ser calculado usando um quociente de Rayleigh

$$r(x_1, A) \equiv \frac{x_1^T A x_1}{x_1^T x_1} \tag{1}$$

Método da Iteração da Potência

- Uma vez que um autovetor x_1 é encontrado, o autovalor correspondente λ_1 pode ser calculado usando um quociente de Rayleigh

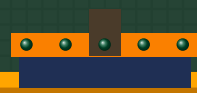
$$r(x_1, A) \equiv \frac{x_1^T A x_1}{x_1^T x_1} \tag{1}$$

- Então, a deflação pode ser realizada construindo uma reflexão de Householder P_1 de modo que $P_1 x_1$ é um múltiplo de e_1 e então $P_1 A P_1$ é uma matriz com estrutura triangular superior de bloco.

Método da Iteração da Potência

- Isso desacopla o problema de calcular os autovalores de A no problema (resolvido) de calculando λ_1, e o de calcular os autovalores do canto inferior direito da submatriz $(n-1) \times (n-1)$.





Método da Iteração da Potência

- Isso desacopla o problema de calcular os autovalores de A no problema (resolvido) de calculando λ_1, e o de calcular os autovalores do canto inferior direito da submatriz $(n-1) \times (n-1)$.
- O método de potência é particularmente útil quando aplicado a uma matriz estocástica direita, que é uma matriz P de ordem $n \times n$, em que cada entrada p_{ij} é a probabilidade de uma transição do estado i para o estado j.





Método da Iteração da Potência

- Isso desacopla o problema de calcular os autovalores de A no problema (resolvido) de calculando λ_1, e o de calcular os autovalores do canto inferior direito da submatriz $(n-1) \times (n-1)$.
- O método de potência é particularmente útil quando aplicado a uma matriz estocástica direita, que é uma matriz P de ordem $n \times n$, em que cada entrada p_{ij} é a probabilidade de uma transição do estado i para o estado j.
- Como as entradas são probabilidades, segue-se que

$$\sum_{j=1}^{n} p_{ij} = 1 \tag{2}$$

- Isto é, todas as somas das linhas devem ser iguais a um.

Método da Iteração da Potência

- Equivalentemente, $Pe = e$, onde e é um vetor com todas as entradas iguais a um.

Método da Iteração da Potência

- Equivalentemente, $Pe = e$, onde e é um vetor com todas as entradas iguais a um.
- Segue-se que e é um autovetor de P, com o autovalor correspondente um.

Método da Iteração da Potência

- Equivalentemente, $Pe = e$, onde e é um vetor com todas as entradas iguais a um.
- Segue-se que e é um autovetor de P, com o autovalor correspondente um.
- De (2), temos que $\|P\|_\infty = 1$.



Método da Iteração da Potência

- Equivalentemente, $Pe = e$, onde e é um vetor com todas as entradas iguais a um.
- Segue-se que e é um autovetor de P, com o autovalor correspondente um.
- De (2), temos que $\|P\|_\infty = 1$.
- Isto implica que $\rho(P) \leq 1$, então o maior autovalor de P é igual a um.



Método da Iteração da Potência

- Equivalentemente, $Pe = e$, onde e é um vetor com todas as entradas iguais a um.
- Segue-se que e é um autovetor de P, com o autovalor correspondente um.
- De (2), temos que $\|P\|_\infty = 1$.
- Isto implica que $\rho(P) \leq 1$, então o maior autovalor de P é igual a um.
- Isso vem do fato de que para qualquer norma matricial induzida, se $Ax = \lambda x$, então

$$|\lambda|\|x\| = \|Ax\| \leq \|A\|\|x\|, \Rightarrow |\lambda| \leq \|A\|$$

portanto, $\rho(A) \leq \|A\|$.

Método da Iteração da Potência

- O autovetor à esquerda de P com autovalor um, que também é um autovetor de P^T, é um vetor em que a j-ésima entrada é a probabilidade de longo prazo de transição para o estado j.

Método da Iteração da Potência

- O autovetor à esquerda de P com autovalor um, que também é um autovetor de P^T, é um vetor em que a j-ésima entrada é a probabilidade de longo prazo de transição para o estado j.
- Podemos tentar calcular esse vetor usando o método de potência.

Método da Iteração da Potência

- O autovetor à esquerda de P com autovalor um, que também é um autovetor de P^T, é um vetor em que a j-ésima entrada é a probabilidade de longo prazo de transição para o estado j.
- Podemos tentar calcular esse vetor usando o método de potência.
- Essas análises ilustram a ideia principal por trás do PageRank, um algoritmo usado pelo Google para classificar os resultados de pesquisa.

Iteração Ortogonal

- Calcular todos os autovalores de A usando o método da potência para obter o maior deles e, em seguida, aplicar deflação pode ser impraticável, mesmo quando A possui autovalores distintos.



Iteração Ortogonal

- Calcular todos os autovalores de A usando o método da potência para obter o maior deles e, em seguida, aplicar deflação pode ser impraticável, mesmo quando A possui autovalores distintos.
- Isso ocorre devido à contaminação dos autovalores menores pelos erros de arredondamento acumulados no cálculo dos autovalores maiores e no processo de deflação.



Iteração Ortogonal

- Calcular todos os autovalores de A usando o método da potência para obter o maior deles e, em seguida, aplicar deflação pode ser impraticável, mesmo quando A possui autovalores distintos.
- Isso ocorre devido à contaminação dos autovalores menores pelos erros de arredondamento acumulados no cálculo dos autovalores maiores e no processo de deflação.
- Uma alternativa é calcular vários autovalores simultaneamente usando uma versão em bloco do método da potência, chamada Iteração Ortogonal.



Iteração Ortogonal

- Calcular todos os autovalores de A usando o método da potência para obter o maior deles e, em seguida, aplicar deflação pode ser impraticável, mesmo quando A possui autovalores distintos.
- Isso ocorre devido à contaminação dos autovalores menores pelos erros de arredondamento acumulados no cálculo dos autovalores maiores e no processo de deflação.
- Uma alternativa é calcular vários autovalores simultaneamente usando uma versão em bloco do método da potência, chamada Iteração Ortogonal.
- Nesse método, a matriz A é multiplicada por uma matriz $n \times r$, com $r > 1$, e a normalização vetorial do método da potência é substituída pela ortogonalização do bloco por meio da fatoração QR fina.



Algoritmo da Iteração Ortogonal

Dados: matriz $\mathbf{A} \in \mathbb{R}^{n\times n}$, e um inteiro positivo r

Saída: calcula um subespaço invariante de A de dimensão r.

1 Escolha uma matriz U_0 de ordem $n \times r$, tal que, $U_0^T U_0 = I_r$

2 **para** $k = 1, 2, \ldots$ *até a convergência* **faça**

3 $\quad Z_k = AU_{k-1}$

4 $\quad Z_k = U_k R_k$ (Fatoração QR fina)

Algoritmo da Iteração Ortogonal

Dados: matriz $\mathbf{A} \in \mathbb{R}^{n\times n}$, e um inteiro positivo r
Saída: calcula um subespaço invariante de A de dimensão r.

1 Escolha uma matriz U_0 de ordem $n \times r$, tal que, $U_0^T U_0 = I_r$
2 **para** $k = 1, 2, \ldots$ *até a convergência* **faça**
3 $\quad Z_k = AU_{k-1}$
4 $\quad Z_k = U_k R_k$ (Fatoração QR fina)

- Em geral, este método produz uma sequência convergente $\{U_k\}$, desde que U_0 tenha componentes nas direções dos autovetores de A^T e que $|\lambda_r| > |\lambda_{r+1}|$.

Algoritmo da Iteração Ortogonal

Dados: matriz $\mathbf{A} \in \mathbb{R}^{n\times n}$, e um inteiro positivo r
Saída: calcula um subespaço invariante de A de dimensão r.

1 Escolha uma matriz U_0 de ordem $n \times r$, tal que, $U_0^T U_0 = I_r$
2 **para** $k = 1, 2, \ldots$ *até a convergência* **faça**
3 $\quad Z_k = AU_{k-1}$
4 $\quad Z_k = U_k R_k$ (Fatoração QR fina)

- Em geral, este método produz uma sequência convergente $\{U_k\}$, desde que U_0 tenha componentes nas direções dos autovetores de A^T e que $|\lambda_r| > |\lambda_{r+1}|$.
- Da relação

$$R_k = U_k^T Z_k = U_k^T A U_{k-1},$$

vemos que, se $U_k \to U$, então $U^T AU = R$ é triangular superior. Além disso, como

$$AU = UR,$$

as colunas de U geram um subespaço invariante de A.

Iteração Ortogonal

- Seja $U^{\perp} \in \mathbb{R}^{n \times (n-r)}$ uma matriz cujas as colunas geram $(\text{range}(U))^{\perp}$, o complemento ortogonal de $\text{range}(U)$.

Iteração Ortogonal

- Seja $U^{\perp} \in \mathbb{R}^{n \times (n-r)}$ uma matriz cujas as colunas geram $(\text{range}(U))^{\perp}$, o complemento ortogonal de $\text{range}(U)$.
- Então, temos que

$$\begin{bmatrix} U^T \\ (U^{\perp})^T \end{bmatrix} A \begin{bmatrix} U & U^{\perp} \end{bmatrix} = \begin{bmatrix} U^T A U & U^T A U^{\perp} \\ (U^{\perp})^T A U & (U^{\perp})^T A U^{\perp} \end{bmatrix}$$

$$= \begin{bmatrix} R & U^T A U^{\perp} \\ 0 & (U^{\perp})^T A U^{\perp} \end{bmatrix}$$

Iteração Ortogonal

- Seja $U^{\perp} \in \mathbb{R}^{n\times(n-r)}$ uma matriz cujas as colunas geram $(\text{range}(U))^{\perp}$, o complemento ortogonal de $\text{range}(U)$.
- Então, temos que

$$\begin{bmatrix} U^T \\ (U^{\perp})^T \end{bmatrix} A \begin{bmatrix} U & U^{\perp} \end{bmatrix} = \begin{bmatrix} U^TAU & U^TAU^{\perp} \\ (U^{\perp})^TAU & (U^{\perp})^TAU^{\perp} \end{bmatrix}$$
$$= \begin{bmatrix} R & U^TAU^{\perp} \\ 0 & (U^{\perp})^TAU^{\perp} \end{bmatrix}$$

- Isto é, $\lambda(A) = \lambda(R) \cup \lambda((U^{\perp})^TAU^{\perp})$, e como R é triangular superior, os autovalores de R são suas entradas diagonais.

Iteração Ortogonal

- Concluímos que a iteração ortogonal, quando converge, produz os maiores autovalores r de A.

Iteração Ortogonal

- Concluímos que a iteração ortogonal, quando converge, produz os maiores autovalores r de A.
- Se $r = n$, e se os autovalores de A são separados em magnitude, então geralmente a iteração ortogonal converge, resultando na decomposição de Schur de A, $A = UTU^T$.

Iteração Ortogonal

- Concluímos que a iteração ortogonal, quando converge, produz os maiores autovalores r de A.
- Se $r = n$, e se os autovalores de A são separados em magnitude, então geralmente a iteração ortogonal converge, resultando na decomposição de Schur de A, $A = UTU^T$.
- No entanto, essa convergência é geralmente muito lenta.

Iteração Ortogonal

- Concluímos que a iteração ortogonal, quando converge, produz os maiores autovalores r de A.
- Se $r = n$, e se os autovalores de A são separados em magnitude, então geralmente a iteração ortogonal converge, resultando na decomposição de Schur de A, $A = UTU^T$.
- No entanto, essa convergência é geralmente muito lenta.
- Para cada inteiro k, definimos $T_k = U_k^T A U_k$.

Iteração Ortogonal

- Concluímos que a iteração ortogonal, quando converge, produz os maiores autovalores r de A.
- Se $r = n$, e se os autovalores de A são separados em magnitude, então geralmente a iteração ortogonal converge, resultando na decomposição de Schur de A, $A = UTU^T$.
- No entanto, essa convergência é geralmente muito lenta.
- Para cada inteiro k, definimos $T_k = U_k^T A U_k$.
- Então, a partir do algoritmo para iteração Ortogonal, temos

$$T_{k-1} = U_{k-1}^T A U_{k-1} = U_{k-1}^T Z_{k-1} = (U_{k-1}^T U_k) R_k = Q_k R_k$$

onde $Q_k = U_{k-1}^T U_k$.

Iteração Ortogonal

- Além disso,

$$\begin{aligned} T_k &= U_k^T A U_k \\ &= U_k^T A U_{k-1} U_{k-1}^T U_k \\ &= U_k^T Z_k U_{k-1}^T U_k \\ &= U_k^T U_k R_k (U_{k-1}^T U_k) \\ &= R_k Q_k \end{aligned}$$

Iteração Ortogonal

- Além disso,

$$\begin{aligned} T_k &= U_k^T A U_k \\ &= U_k^T A U_{k-1} U_{k-1}^T U_k \\ &= U_k^T Z_k U_{k-1}^T U_k \\ &= U_k^T U_k R_k (U_{k-1}^T U_k) \\ &= R_k Q_k \end{aligned}$$

- Isto é, T_k é obtido a partir de T_{k-1} pela cálculo de fatoração QR de T_{k-1}, e então multiplicando os fatores na ordem inversa.



Iteração Ortogonal

- Equivalentemente, T_k é obtido pela aplicação de transformação de similaridade de T_{k-1}, como

$$T_k = R_k Q_k = Q_k^T T_{k-1} Q_k$$

Iteração Ortogonal

- Equivalentemente, T_k é obtido pela aplicação de transformação de similaridade de T_{k-1}, como

$$T_k = R_k Q_k = Q_k^T T_{k-1} Q_k$$

- Se a interação ortogonal converge, então T_k converge para uma matriz triangular superior $T = U^T A U$ cuja as entradas da digoanal são os autovalores de A.

Algoritmo da Iteração QR

- Este processo simples de calcular repetidamente a fatoração QR e multiplicar os fatores na ordem inversa, é chamada de Iteração QR, que procede da seguinte forma:

Algoritmo da Iteração QR

- Este processo simples de calcular repetidamente a fatoração QR e multiplicar os fatores na ordem inversa, é chamada de Iteração QR, que procede da seguinte forma:

Dados: matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$, e um inteiro positivo r
Saída: calcula a decomposição de Schur $A = QTQ^T$ de A

1 Escolha Q_0, tal que, $Q_0^T Q_0 = I_n$
2 $T_0 = Q_0^T A Q_0$
3 **para** $k = 1, 2, \ldots$ *até a convergência* **faça**
4 $\quad T_{k-1} = Q_k R_k$ (Fatoração QR)
5 $\quad T_k = R_k Q_k$

Iteração QR

- Esta versão da iteração ortogonal serve de base para um algoritmo eficiente de cálculo de autovalores, conhecido como algoritmo QR.



Iteração QR

- Esta versão da iteração ortogonal serve de base para um algoritmo eficiente de cálculo de autovalores, conhecido como algoritmo QR.
- Entretanto, conforme descrita, a iteração QR é computacionalmente cara, pois operações da ordem de $O(n^3)$ são necessárias em cada iteração para calcular a fatoração QR de T_{k-1}. Além disso, normalmente são necessárias muitas iterações até a convergência.

Iteração QR

- Esta versão da iteração ortogonal serve de base para um algoritmo eficiente de cálculo de autovalores, conhecido como algoritmo QR.
- Entretanto, conforme descrita, a iteração QR é computacionalmente cara, pois operações da ordem de $O(n^3)$ são necessárias em cada iteração para calcular a fatoração QR de T_{k-1}. Além disso, normalmente são necessárias muitas iterações até a convergência.
- Se A é uma matriz real com autovalores complexos, a iteração QR pode não convergir para uma matriz diagonal real, devido à presença de pares de autovalores complexos conjugados com mesmo módulo. Nesse caso, a convergência ocorre para uma forma quase triangular, com blocos reais 2×2 associados aos autovalores complexos.



